

VIDEO GAMES SALES

KAGGLE

Estud-IA

ANALISIS DE DATOS

JOSE MIGUEL RICO ACOSTA

1. Introducción

El presente documento tiene como finalidad registrar y documentar el proceso realizado durante el curso de Análisis de Datos aplicado a una base de datos de ventas de videojuegos, utilizando diferentes herramientas trabajadas a lo largo del curso. En este documento se describen las etapas de limpieza, transformación, consultas, análisis y visualización de datos desarrolladas durante el trabajo.

Para el procesamiento y análisis de la información se utilizaron PostgreSQL y pgAdmin para la limpieza, transformación y consultas SQL sobre los datos. Adicionalmente, se utilizó RStudio para algunos análisis estadísticos descriptivos y Microsoft Power BI para la visualización e interpretación de la información mediante dashboards interactivos.

La base de datos utilizada corresponde a un dataset de ventas de videojuegos obtenido desde Kaggle, el cual contiene información sobre títulos, plataformas, géneros, compañías distribuidoras y ventas registradas en diferentes regiones del mundo.

2. Planteamiento del problema

El crecimiento de la industria de los videojuegos ha generado grandes volúmenes de datos relacionados con ventas, plataformas, géneros y comportamiento del mercado. Sin embargo, los datasets obtenidos desde fuentes abiertas suelen presentar inconsistencias, valores faltantes y problemas de calidad que dificultan su análisis.

Por esta razón, surge la necesidad de realizar un proceso de limpieza, transformación y análisis de datos que permita obtener información confiable y útil para identificar patrones de ventas y tendencias dentro de la industria de los videojuegos.

3. Objetivo General

Analizar el comportamiento de las ventas de videojuegos mediante procesos de limpieza, transformación, análisis estadístico y visualización de datos utilizando diferentes herramientas de análisis de datos.

4. Objetivos Específicos

- Limpiar y transformar los datos utilizando PostgreSQL y SQL.
- Validar la calidad e integridad de la información.
- Aplicar técnicas estadísticas descriptivas en RStudio.
- Desarrollar dashboards interactivos en Power BI.
- Identificar patrones y tendencias en las ventas globales de videojuegos.

5. Descripción de la Base de Datos

La base de datos utilizada ya había sido trabajada y vista en el curso, esta fue obtenida desde la plataforma Kaggle y contiene información relacionada con ventas de videojuegos a nivel global. El dataset incluye información histórica sobre títulos de videojuegos, plataformas, géneros, compañías distribuidoras y ventas registradas en diferentes regiones del mundo.

La información permite realizar distintos tipos de análisis relacionados con el comportamiento del mercado de videojuegos, tendencias de ventas, plataformas más exitosas, géneros más populares y distribución de ventas por regiones.

La base de datos original contiene variables como:

- Ranking global del videojuego.
- Nombre del videojuego.
- Plataforma.
- Año de lanzamiento.
- Género.
- Compañía distribuidora.
- Ventas en Norteamérica.
- Ventas en Europa.
- Ventas en Japón.
- Ventas en otras regiones.
- Ventas globales.

Con el fin de organizar mejor la información y facilitar el manejo de los datos en bases de datos relacionales, el dataset fue dividido en dos tablas principales:

Tabla: video_games

Contiene la información general y descriptiva de los videojuegos:

- Rank - BIGINT
- Name - STRING
- Platform - STRING
- Year - STRING
- Genre – STRING

Tabla: video_games_sales

Contiene la información relacionada con las ventas:

- Rank - BIGINT
- Publisher - STRING
- NA_Sales – REAL ⚠ (STRING)
- EU_Sales - REAL
- JP_Sales - REAL
- Other_Sales - REAL
- Global_Sales – REAL

Ambas tablas se relacionan mediante la columna Rank, utilizada como identificador común entre ellas (PK). Esta división permitió trabajar de forma más organizada mediante consultas SQL, JOINS y procesos de análisis posteriores.

Durante la exploración inicial de los datos se identificaron diferentes inconsistencias que requerían limpieza y transformación antes de realizar el análisis, entre ellas:

- Valores nulos.
- Datos inconsistentes.
- Registros inválidos.
- Tipos de datos incorrectos.
- Valores no numéricos en columnas de ventas.

A partir de esta revisión se realizó el proceso de limpieza y transformación de datos utilizando principalmente consultas de SQL en pgAdmin, preparando la información para su posterior análisis y visualización.

6. Preparación y Organización de los Datos

En esta etapa se realizó el proceso de limpieza, transformación y organización de los datos utilizando consultas SQL en PostgreSQL mediante pgAdmin. El objetivo principal fue corregir inconsistencias presentes en el dataset original y preparar la información para su posterior análisis y visualización.

6.1 Limpieza de la Tabla video_games

✓ Limpieza de la columna Name

Se identificaron registros cuyos nombres contenían patrones no deseados, como valores iniciados con “.hack”. Estos registros fueron corregidos eliminando únicamente dicho patrón, conservando el resto de la información original.

✓ Eliminación de registros nulos

Se detectaron filas con múltiples valores nulos en columnas importantes como:

- Platform
- Year
- Genre

Debido a que estos registros no aportaban valor para el análisis, fueron eliminados del dataset.

✓ Limpieza de la columna Year

Durante la revisión de esta columna se identificaron diferentes inconsistencias, entre ellas:

- Valores tipo “N/A”
- Texto en lugar de años
- Datos desordenados entre columnas

Para solucionar estos problemas se realizaron las siguientes acciones:

- Reemplazo de “N/A” por valores NULL
- Eliminación de registros con valores no numéricos
- Eliminación de 109 registros con inconsistencias estructurales

✓ Conversión de tipo de dato

Posteriormente, la columna Year fue convertida de tipo STRING a INTEGER, permitiendo su utilización en consultas, análisis y visualizaciones posteriores.

6.2 Limpieza de la Tabla video_games_sales

✓ Integridad referencial

Debido a la eliminación de registros en la tabla video_games, se eliminaron registros huérfanos en la tabla video_games_sales para mantener la consistencia entre ambas tablas.

✓ Limpieza de la columna Publisher

Se identificaron valores "N/A", los cuales fueron reemplazados por NULL con el fin de estandarizar los datos faltantes.

✓ Limpieza de la columna NA_Sales

En esta columna se detectaron valores inválidos como:

- " Inc"
- "Inc."

Para solucionar estas inconsistencias se realizaron las siguientes acciones:

- Conversión de valores inválidos a NULL
- Validación de datos numéricos

✓ Conversión de tipo de dato

La columna NA_Sales fue convertida de tipo STRING a REAL, permitiendo trabajar correctamente con operaciones numéricas y análisis estadísticos.

6.3 Resultados del Proceso de Limpieza

Después del proceso de preparación y limpieza:

- Los datos quedaron estructurados y consistentes
- Se eliminaron registros corruptos o no confiables
- Se normalizaron valores nulos
- Se corrigieron tipos de datos
- Se garantizó la integridad entre tablas

Este proceso permitió obtener un dataset limpio y confiable para las etapas posteriores de análisis y visualización de datos.

7. Visualización y Análisis de Datos en Power BI

Con el fin de facilitar la interpretación y análisis de la información, se desarrolló un dashboard interactivo en Microsoft Power BI enfocado en el análisis global de ventas de videojuegos.

7.1 Dashboard - Overview

El dashboard principal, denominado "Overview", permite visualizar de manera general el comportamiento de las ventas globales de videojuegos mediante indicadores clave y gráficos comparativos.

✓ KPIs Implementados

El dashboard incluye diferentes indicadores principales que permiten resumir el comportamiento general del dataset:

- Total de videojuegos registrados.
- Total de ventas globales.
- Plataforma con mayores ventas.
- Género con mayores ventas.

Estos indicadores permiten obtener una visión rápida del estado general de la información analizada.

✓ Visualizaciones Utilizadas

Para representar la información se utilizaron diferentes tipos de visualizaciones:

- **Gráfico de barras – Ventas por Género**

Este gráfico permite identificar los géneros con mayores ventas globales. A partir del análisis realizado se observa que el género Action presenta el mayor volumen de ventas dentro del dataset.

- **Gráfico de barras – Ventas por Plataforma**
- Esta visualización muestra la distribución de ventas por plataforma de videojuegos, permitiendo comparar el rendimiento comercial entre diferentes consolas.

Dentro del análisis realizado se identifica que la plataforma PS2 presenta el mayor volumen de ventas globales.

Objetivo del Dashboard

El objetivo principal del dashboard es proporcionar una visión general del comportamiento del mercado de videojuegos, permitiendo identificar:

- Géneros más vendidos.
- Plataformas con mejores resultados.
- Distribución global de ventas.
- Tendencias generales del mercado.

Resultados

A partir del análisis visual realizado se identificaron algunos hallazgos importantes:

- El género Action domina las ventas globales dentro del dataset analizado.
- La plataforma PS2 registra el mayor volumen de ventas.
- Existen diferencias significativas entre plataformas en términos de ventas acumuladas.
- Algunos géneros presentan una participación considerablemente menor dentro del mercado global.

7.2 Dashboard – Análisis por Región

Con el objetivo de profundizar en el comportamiento de las ventas según diferentes regiones del mundo, se desarrolló un segundo dashboard denominado “Análisis por Región”. Este dashboard permite analizar de forma dinámica el comportamiento de las ventas en regiones como Europa, Norteamérica, Japón y otras regiones incluidas en el dataset.

La visualización incorpora filtros interactivos que permiten cambiar la región analizada y observar variaciones en plataformas, géneros y comportamiento histórico de ventas.

✓ KPIs Implementados

El dashboard incluye indicadores enfocados en la región seleccionada:

- Ventas totales por región.
- Plataforma con mayores ventas.
- Género con mejor rendimiento comercial.

Estos indicadores permiten comparar rápidamente el comportamiento del mercado entre diferentes regiones.

✓ **Visualizaciones Utilizadas**

Para representar la información se utilizaron diferentes tipos de visualizaciones:

- **Ventas por Plataforma**

Se implementó un gráfico de barras para visualizar las plataformas con mayores ventas dentro de la región seleccionada.

En el caso de Europa, se observa que la plataforma PS3 presenta uno de los mayores volúmenes de ventas.

- **Evolución Temporal de Ventas**

Se utilizó un gráfico de líneas para representar el comportamiento histórico de las ventas a lo largo del tiempo.

Esta visualización permite identificar:

- crecimiento del mercado,
- años con mayores ventas,
- y disminuciones en determinados periodos.

Dentro del análisis realizado se evidencia un crecimiento importante entre los años 2000 y 2010.

- **Ventas por Género**

Se desarrolló un gráfico comparativo para identificar los géneros con mayores ventas dentro de la región seleccionada.

En Europa, el género Action presenta nuevamente el mayor volumen de ventas, seguido por Sports y Shooter.

- **Distribución de Ventas por Región**

Se implementó un gráfico circular para representar la participación porcentual de cada región dentro de las ventas globales.

Esta visualización permite comparar la contribución de:

- Europa,
- Norteamérica,
- Japón,
- y otras regiones.

✓ **Segmentadores y Navegación**

El dashboard incluye botones y filtros interactivos que permiten navegar entre distintas regiones:

- Europa
- Global
- Japón
- Norteamérica
- Otros

Esto facilita realizar comparaciones dinámicas y explorar el comportamiento de ventas según diferentes mercados.

Objetivo del Dashboard

El objetivo principal del dashboard “Análisis por Región” es analizar el comportamiento de las ventas de videojuegos en diferentes regiones del mundo, permitiendo identificar variaciones en plataformas, géneros y tendencias de ventas según cada mercado.

Mediante este dashboard es posible comparar el rendimiento comercial entre regiones como Europa, Norteamérica, Japón y otras regiones, facilitando la identificación de patrones de consumo, preferencias de plataformas y géneros con mayor impacto en cada zona geográfica.

Resultados

A partir del análisis visual realizado se identificaron algunos hallazgos importantes:

- Las preferencias de plataformas varían según la región analizada.
- El género Action mantiene un alto volumen de ventas en múltiples regiones.
- Las ventas presentan un crecimiento significativo entre los años 2000 y 2010.
- Norteamérica y Europa representan una gran parte de las ventas globales del dataset.
- Algunas plataformas tienen un comportamiento más fuerte en regiones específicas.

8. Análisis Estadístico en RStudio

Con el objetivo de complementar el análisis realizado en PostgreSQL y Power BI, se desarrolló un análisis estadístico descriptivo utilizando RStudio. Para este proceso se trabajó con la base de datos consolidada y limpia denominada **videogamessales_clean**.

Durante esta etapa se aplicaron diferentes técnicas estadísticas descriptivas sobre la variable **Global_Sales** aprendidas al principio del curso, permitiendo analizar el comportamiento de las ventas globales de videojuegos mediante tablas de frecuencia, medidas estadísticas y representaciones gráficas.

8.1 Preparación de los Datos

Inicialmente se cargaron las librerías necesarias para el análisis y visualización de datos:

- dplyr
- ggplot2
- fdth
- e1071
- lattice

Posteriormente, se asignó la base de datos principal a la variable datos para facilitar el desarrollo del análisis estadístico.

- **Conversión y validación de datos**

Durante la importación del dataset se identificaron valores "N/A" en algunas columnas numéricas, lo que provocaba que fueran interpretadas como variables de tipo carácter. Para solucionar este problema se reemplazaron dichos valores por NA.

Las columnas:

- Year
- NA_Sales

fueron posteriormente convertidas a tipo numérico mediante funciones de conversión en R.

Finalmente, se realizaron verificaciones generales utilizando funciones como:

- head()
- summary()
- str()
- sapply()

permitiendo validar la estructura, tipos de datos y contenido del dataset.

8.2 Análisis de la Variable Global_Sales

La variable **Global_Sales** fue seleccionada como principal objeto de estudio debido a que representa las ventas globales de videojuegos y constituye una de las métricas más importantes dentro del análisis realizado.

Inicialmente se organizó la variable para facilitar su procesamiento estadístico y posterior generación de tablas de frecuencia y gráficas.

8.3 Tabla de Frecuencia

Para analizar la distribución de las ventas globales se construyó una tabla de frecuencia agrupada utilizando la librería fdth.

El número de intervalos fue calculado mediante la fórmula de Sturges:

$$K_G = 1 + 3.32 * \log_{10}(\text{length}(\text{Global_Sales}))$$

Posteriormente se calcularon:

- Número de clases
- Valor máximo
- Valor mínimo
- Rango
- Amplitud de clase
- Rango ampliado

Con estos valores se generó la tabla de distribución de frecuencias para la variable **Global_Sales**.

La tabla permitió identificar la concentración de registros dentro de determinados intervalos de ventas.

8.4 Representaciones Gráficas

A partir de la tabla de frecuencia y los datos analizados se desarrollaron diferentes representaciones gráficas para visualizar el comportamiento de las ventas globales.

Gráficas realizadas

- Histograma
- Polígono de frecuencias
- Gráfico de distribución de frecuencias

- Diagrama de caja y bigotes
- Curva de densidad
- Gráfica de torta sobre participación de ventas por género

La gráfica de torta permitió visualizar la participación porcentual de ventas globales según el género de los videojuegos, facilitando la identificación de los géneros con mayor impacto comercial dentro del dataset.

Por otra parte, el diagrama de caja y bigotes permitió detectar la presencia de valores atípicos asociados a videojuegos con ventas considerablemente superiores al promedio.

8.5 Medidas de Tendencia Central

Se calcularon diferentes medidas de tendencia central sobre la variable Global_Sales.

Medidas calculadas

- Media
- Mediana

Estas medidas permitieron identificar el comportamiento promedio de las ventas globales dentro del dataset.

Adicionalmente, mediante la tabla de frecuencias se identificó el intervalo modal con mayor concentración de registros.

8.6 Medidas de Dispersión

Con el fin de analizar la variabilidad de los datos, se calcularon diferentes medidas de dispersión.

Medidas calculadas

- Rango
- Desviación estándar
- Varianza

Estas medidas permitieron evaluar qué tan dispersas se encuentran las ventas respecto al promedio general.

8.7 Medidas de Posición

También se calcularon medidas de posición para analizar la distribución de los datos.

Medidas calculadas

- Cuartiles
- Rango intercuartílico

El análisis permitió identificar la dispersión del 50% central de los datos y detectar posibles valores atípicos.

8.8 Análisis de Distribución

Mediante el diagrama de caja y bigotes, el coeficiente de asimetría y la curtosis, se analizaron las características de la distribución de **Global_Sales**.

Los resultados obtenidos indican que:

- La distribución presenta asimetría positiva (asimétrica hacia la derecha).
- Existen bastantes valores atípicos asociados a videojuegos con ventas considerablemente superiores al promedio.
- La distribución presenta un comportamiento leptocúrtico, evidenciando una mayor concentración de datos alrededor de la media.

La curva de densidad permitió complementar visualmente el comportamiento de la distribución de los datos.

8.9 Resultados del Análisis Estadístico

A partir del análisis estadístico realizado se identificaron algunos aspectos importantes:

- Las ventas globales presentan una distribución dispersa.
- Existen videojuegos con ventas significativamente superiores al promedio.
- La mayoría de los registros se concentran en intervalos “bajos” de ventas.
- Se identificaron valores atípicos dentro del dataset.
- El análisis estadístico complementó los resultados obtenidos previamente en Power BI y PostgreSQL.

Este proceso permitió aplicar diferentes técnicas estadísticas trabajadas durante el curso y complementar el análisis exploratorio realizado sobre la base de datos de ventas de videojuegos.